

Part A - Theory Recap

Part B - Calculation Exercises

Corpus $D_1 = \text{"cat eats fish"}$
 $D_2 = \text{"dog eats fish"}$
 $D_3 = \text{"cat likes fish"}$

Vocabulary [cat, dog, eats, fish, likes]

Exercise 1:

$$D_1 = [1, 0, 1, 1, 0]$$
$$D_2 = [0, 1, 1, 1, 0]$$
$$D_3 = [1, 0, 0, 1, 1]$$

Exercise 2: TF

$$tf(\text{cat}, D_1) = \frac{1}{3} ; tf(\text{fish}, D_1) = \frac{1}{3} ; tf(\text{eats}, D_1) = \frac{1}{3}$$

$$\sum_t tf(t, D_1) = \frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1$$

Exercise 3: IDF

$$N = 3$$

$$idf(t) = \log \frac{N}{df(t)}$$

$$idf(\text{cat}) = \log \frac{3}{2}$$

$$idf(\text{dog}) = \log \frac{3}{1} = \log 3$$

$$idf(\text{eats}) = \log \frac{3}{2}$$

$$idf(\text{fish}) = \log \frac{3}{3} = \log 1 = 0$$

$$idf(\text{likes}) = \log \frac{3}{1} = \log 3$$

$$\left. \begin{array}{l} df(\text{cat}) = 2 \\ df(\text{dog}) = 1 \\ df(\text{eats}) = 2 \\ df(\text{fish}) = 3 \\ df(\text{likes}) = 1 \end{array} \right\}$$

Term có idf thấp nhất là fish. Do fish xuất hiện trong cả 3 documents $\Rightarrow$ không giúp phân biệt documents trong corpus

Exercise 4: TF - IDF

$$tfidf(t, d) = tf(t, d) \times idf(t)$$

$$tf(cat, D_1) = tf(eats, D_1) = tf(fish, D_1) = \frac{1}{3}$$

$$idf(cat) = idf(eats) = \log \frac{3}{2}, \quad idf(fish) = 0$$

$$\bullet \quad tfidf(cat, D_1) = \frac{1}{3} \cdot \log \frac{3}{2} \approx 0,1852$$

$$\bullet \quad tfidf(eats, D_1) = \frac{1}{3} \log \frac{3}{2} \approx 0,1852$$

$$\bullet \quad tfidf(fish, D_1) = \frac{1}{3} \cdot 0 = 0$$

fish xuất hiện trong mọi document nhưng TF-IDF của nó bằng 0 theo công thức do một term quá phổ biến trong toàn corpus có khả năng phân biệt thấp

Exercise 5: Cosine similarity

$$x = [1, 1, 1]$$

$$y = [1, 1, 0]$$

$$\cos(x, y) = \frac{2}{\sqrt{3} \cdot \sqrt{2}} = \frac{2}{\sqrt{6}}$$

Hai documents có hai term giống nhau trên ba term tổng cộng. Cosine similarity không bằng $\frac{2}{3}$ vì cosine similarity không tính đến giá trị bằng

HAI TIEN

số term giống nhau
tổng số term

mà là góc giữa 2 vector
sau khi chuẩn hóa theo độ
dài vector

Exercise 6: Prediction

1. Document có similarity cao nhất : D_1
2. Document có similarity thấp nhất : D_3
3. Term có thể có giá trị IDF thấp :
medical, image (do xuất hiện 2/3 documents)
4. Nếu bỏ IDF và chỉ sử dụng count vector thì
ranking có thể không đổi.

Vì D_1 có 3/3 term giống Q $D_1 > D_2 > D_3$
 D_2 có 2/3 term giống Q
 D_3 có 0/3 term giống Q