

Part C - Prediction Before Experiment

⊕ Prediction 1 - Vocabulary

Nếu corpus có 30K documents, vocabulary sẽ có khoảng bao nhiêu unique terms?

$$30.000 \cdot 15 / 3 = 450.000 / 3 = 150.000$$

(Đo đang ước lượng trung bình một document có khoảng 15 từ và giả định unique terms chiếm 1/3)

⊕ Prediction 2 - Sparsity

TF-IDF matrix sẽ dense hay sparse? sparse

Tỷ lệ zero entries có thể lớn đến mức nào? Khoảng 70%.

⊕ Prediction 3 - Search

Với một query bất kỳ:
Các documents đứng đầu kết quả tìm kiếm có nhất thiết là documents gần nghĩa nhất không?

Không nhất thiết. Với các bài đang xét chủ yếu đề cập đến sự trùng khớp giữa các term chứ không phải về mặt ngữ nghĩa.

Ví dụ: "Bạn liên lạc bạn" với "Bạn liên lạc không bạn" trùng khớp đến 3 terms nhưng trái nghĩa nhau hoàn toàn.