

Part H: Evaluation

1. Relevant

0. Not relevant

Query 1: medical image classification

Rank	Document ID	Similarity	Relevant
1	D18971	0,4	0
2	D8527	0,55	0
3	D19908	0,2534	0
4	D17794	0,2405	0
5	D12658	0,2331	0

Không có document nào trong Top-5 thực sự nói về medical image classification. D12658 có nói đến liên quan đến medical devices nhưng không nói về phân loại ảnh y tế. D17794 liên quan đến image metadata nhưng cũng không phải medical image classification.

Query 2: transformer language model

Rank	Document ID	Similarity	Relevant
1	D27936	0,4718	0
2	D25428	0,2791	0
3	D4075	0,2227	0
4	D701	0,2161	0
5	D13690	0,2136	0

Không có document nào trong Top-5 thực sự nói về transformer language model.

D27936 đứng đầu với similarity cao nhất nhưng
nội dung nói về transformer / circuit board,
không phải transformer trong NLP
D25428 có nội dung về language trên iPhone
nhưng không nói về transformer language model

Query 3: deep learning healthcare

Rank	Document ID	Similarity	Relevant
1	D9252	0,2782	0
2	D6123	0,2753	0
3	D11119	0,2747	0
4	D11979	0,2730	0
5	D7564	0,2405	0

Các document đứng đầu chủ yếu nói về
healthcare. D11119 nói về Big Data trong healthcare
D11979 nói về đào tạo quản lý healthcare
D7564 lại chủ yếu nói về cách sử dụng hệ "learning"
Do đó, similarity đến hệ sẽ xuất hiện của các
từ liên quan đến "healthcare" hoặc learning,
chủ yếu phản ánh đây là ý nghĩa của cụm
"deep learning healthcare".

Query 4: natural language processing

Rank	Document ID	Similarity	Relevant
1	D25428	0,5627	0
2	D8705	0,3418	0
3	D4075	0,289	0
4	D5699	0,2829	0
5	D701	0,2805	HAI TIEN 0

không có document nào trong top 5 thực sự tập trung vào natural language processing. D25428 nói về ngôn ngữ trên iPhone. D5699 có cụm "natural language" nhưng nói dung chính là về "truth value gaps" trong ngôn ngữ tự nhiên. D8705 nói về food processing chứ không phải language processing.

Query 5: machine learning classification

Rank	DocumentID	Similarity	Relevant
1	D18971	0,3938	0
2	D8527	0,3446	0
3	D2501	0,2528	1
4	D21822	0,2415	0
5	D19280	0,2374	0

D2501 được đánh dấu relevant vì document nói rõ về việc sử dụng machine learning để dự đoán nguy cơ PTSD và hỗ trợ chuẩn đoán. Đây là document gần với nội dung machine learning và classification/prediction hơn các document còn lại.

D18971 và D8527 có similarity cao nhưng chủ yếu là liên quan đến từ "classification" trong khi không nói về machine learning.

Query 6: image processing

Rank x	Document ID	Similarity	Relevant
1	D8705	0,4068	0
2	D19908	0,3408	0
3	D17794	0,3234	0
4	D15682	0,3133	0
5	D8320	0,3027	1

D8320 được đánh dấu relevant vì document nói trực tiếp về Image processing technology, bao gồm các ứng dụng như identifying, measuring objects và Telemedicine.

D8705 đứng đầu nhưng nội dung nói về food processing, không phải image processing.

Precision @ 5 = số document trong Top-5 / 5

~~P@5~~

Query

P@5

1

0

2

0

3

0

4

0

5

0,2

6

0,2

Recall @ 5 = số relevant trong Top-5 / tổng số relevant documents → chưa biết

$$MRR = (0 + 0 + 0 + 0 + 1/3 + 1/5) / 6$$

$$= 0,0889$$

Part I: Error Analysis

① 2Q tốt

a) machine learning classification

- D18971 đứng đầu vì có nhiều từ liên quan đến classification, trùng với query.
- Từ đóng góp: classification
- Lexical overlap: có
- Relevant bị xếp thấp chỉ ở rank 3
- Nguyên nhân: TF-IDF dựa nhiều vào lexical matching, chưa hiểu đầy đủ ngữ nghĩa của machine learning classification và environmental classification.

b) image processing

- D8705 đứng đầu vì chứa nhiều từ liên quan đến processing
- Từ đóng góp: processing
- Lexical overlap: có
- Relevant bị xếp ở rank 5
- Nguyên nhân: TF-IDF không phân biệt được image processing với food processing

② 2Q xấu:

a) transformer language model

- D27936 đứng đầu do có từ transformer trùng trực tiếp với query.
- Từ đóng góp: transformer, một phần model
- Lexical overlap: có
- Relevant bị bỏ sót: K^o có trong top-5
- Nguyên nhân: transformer trong document nói về thiết bị điện, trong khi query nói về Transformer

HAI TIEN

Trong NLP TF-IDF không hiểu khác biệt về ngữ nghĩa.

- D25428 đứng đầu do có nhiều từ liên quan đến language.
- Từ đóng góp: language, processing
- Lexical overlap: Có
- K° có relevant trong Top 5 vì language và processing xuất hiện trong nhiều ngữ cảnh khác nhau nhưng TF-IDF không hiểu toàn bộ cụm natural language processing.

(*) Failure Case: transformer language model
D27936 đứng rank 1 với similarity 0,4718
những document nói về transformer / circuit board.
Không phải Transformer trong NLP.
→ lexical matching failure

Part I:
Có thể sử dụng word embeddings / contextual embeddings, trong đó các từ xuất hiện trong những ngữ cảnh tương tự được biểu diễn bằng các vector gần nhau. Nhờ đó, hệ thống có thể đo similarity về nghĩa thay vì chỉ dựa vào sự trùng khớp từ.

Learning Check

Q1: Vì mỗi document chỉ chứa một phần nhỏ vocabulary nên phần lớn giá trị TF-IDF bằng 0, tạo ra vector thưa.

Q2: Vì term xuất hiện trong nhiều documents nên ít có khả năng phân biệt document này với document khác nên thấp.

Q3: IDF chỉ thể hiện độ hiếm của term. Nếu term đó không xuất hiện hoặc có TF thấp trong document thì TF-IDF vẫn thấp.

Q4: Vì cosine similarity đo góc giữa các vector, ít bị ảnh hưởng bởi độ dài document và phù hợp để so sánh các vector TF-IDF.

Q5: Vì preprocessing quyết định các term được giữ lại và cách chúng được biểu diễn, từ đó làm thay đổi vocabulary, TF-IDF và similarity.

Q6: Query transformer language model trả về document nói về transformer/circuit board ở rank 1 do có từ transformer trùng với query, mặc dù khác nghĩa.

Q7: Điều này gợi ý cần representation có khả năng biểu diễn ngữ nghĩa, chẳng hạn word embeddings hoặc contextual embeddings.

Part K: Reflection

1. Prediction nào của em sai?

Prediction về ~~các~~ vocabulary size trong đời gần kết quả thực tế, tuy nhiên với lượng ban đầu còn đơn giản. Prediction về sparsity và việc TF-IDF chủ yếu dựa trên bề trùng khớp term phù hợp với kết quả thực nghiệm.

2. Kết quả nào bất ngờ nhất?

Kết quả bất ngờ nhất là một số documents có similarity cao nhưng không thực sự liên quan đến query. Ví dụ, query "transformer language model" trả về document nói về "transformer / circuit board" ở vị trí đầu tiên.

3. Experiment nào cung cấp evidence mạnh nhất? Phần Error Analysis cung cấp evidence rõ nhất vì có thể quan sát trực tiếp các trường hợp TF-IDF trả về document có lexical overlap nhưng khác về ngữ nghĩa.

4. Failure case quan trọng nhất là gì?

Failure case quan trọng nhất là "transformer language model" trong đó "transformer" xuất hiện nhưng mang 2 nghĩa khác nhau. Điều này cho thấy hạn chế của lexical matching.

5. Nếu được giữ xây lại search engine, em sẽ thay đổi điều gì?

Em sẽ giữ TF-IDF làm baseline và bổ sung

HAI TIEN

"n-gram hoặc embedding-based representation" để cải thiện khả năng tìm kiếm theo ngữ nghĩa.

6. AI đã được sử dụng ở những phần nào và đóng góp cụ thể là gì?

- Giải thích và kiểm tra các hàm trong phần implementation / experiments / ...
- Hỗ trợ xây dựng và kiểm tra unit test.
- Giải thích các pipeline A, B, C (đã biết là C)
- Hỗ trợ kiểm tra lỗi code và điều chỉnh chương trình trong quá trình thực hiện.