[11] Experiment 1 - Dataset inspection
Dataset không bị mất cân bằng lớp vì 2 lớp positive và negative có số lượng bằng nhau, chiếm 50% tổng số mẫu.

[12] - Data leakage.
Fit TF-IDF trên toàn bộ dataset trước khi chia train/test là data leakage do thông tin từ tập test được sử dụng để xây dựng vocabulary và tính IDF → quá trình huấn luyện không độc lập với test, đánh

HAI TIEN

Được quét bằng CamScanner

giá thiết khách quan

16 Tại sao 2 representation tạo ra kết quả khác nhau?

	TF-IDF	Word2Vec Average
Bản chất vector	Thưa thớt, số chiều lớn	Dense, số chiều thấp
Thông tin lưu giữ	Giữ tần suất và trọng số từ	Lưu giữ nghĩa tương đồng giữa các từ
Độ nhạy với từ khoá cảm xúc	Rất cao: Các từ biểu cảm mạnh có IDF cao	Bị giảm: tính trung bình cộng vector → loãng cảm xúc mạnh
Thứ tự từ	Không giữ thứ tự từ	Không giữ thứ tự từ

Vd trong bài toán phân loại sắc thái bình luận phim, các từ vựng đặc trưng thể hiện thái độ quyết định TF-IDF → gán trọng số cho từ khoá này. Average Word2Vec mất đi mức độ do phép trung bình trên văn bản dài.

17 Q4 - Word order

Representation này không hiểu được vai trò của "not" do Average Word2Vec biểu diễn văn bản theo công thức $\vec{x} = \frac{1}{n}\sum_{i=1}^{n} \vec{w_i}$ và vector của từ "not" chỉ đóng vai trò của 1 thành phần cộng dồn thêm vào trung bình và không có cơ chế phủ định hay đảo chiều ⇒ cosine vẫn cao → mô hình dự đoán sai

HAI TIEN

Được quét bằng CamScanner

18 Đ5 - n-gram

Vì ~~sao~~ Bigram có thể giúp classification những dòng thơ làm feature space lớn hơn là vì bigram bắt được các cụm từ liền kề mang sắc thái rõ rệt hoặc chứa từ phủ định như "not good", → cụm từ thành đặc trưng, giải quyết điểm yếu mất thứ tự từ của unigram.

Bên cạnh đó, số lượng các tổ hợp 2 từ liền kề V×V là rất lớn, mà trận đặc trưng thưa hơn rất nhiều.

20 Confusion matrix

- Class negative bị nhầm nhiều nhất ở cả 3 mô hình.

Model	Số lần đoán sai (negative)	% Positive (lần)
A	268	229
B	383	352
C	263	235

- False positive chiếm nhiều hơn False negative ở cả 3 model. FP > FN

→ xu hướng over predicting positive ⇒ dễ bị đánh lừa bởi một vài từ mang tính tích cực (thực chất có thể là negative)

Được quét bằng CamScanner

[22] Các feature có ý nghĩa với bài toán sentiment analysis.

Nhóm positive ($w_i > 0$) tập trung vào các từ khen ngợi như great (+8,45), excellent (+7,314)...

Nhóm negative ($w_i << 0$) bao gồm các từ phê bình như worst (-10,997), waste (-7,575)... → Điểm rơi xuống → Mô hình tuyến tính

HAI TIEN

Được quét bằng CamScanner

25 Learning check

1. Do mất cân bằng dữ liệu. Nếu 95% dữ liệu là negative thì chỉ cần đoán hết là negative thì accuracy > 95%. Cần xem thêm Precision, Recall, F_1.

2. - TF-IDF: thưa, dựa trên mặt chữ, giữ nguyên trong số của từng cảm xúc.

- Avg Word2vec: dày đặc, hiểu ngữ nghĩa, lấy trung bình cộng làm phẳng loãng tín hiệu cảm xúc quan trọng

3. "not good" có thể gây lỗi do mô hình mất thứ tự từ. Từ "good" có trọng số dương rất lớn kéo thành positive. Mô hình không hiểu từ "not" đứng trước đảo nghĩa từ "good".

4. Data leakage xảy ra ở vocabulary và chỉ số TF-IDF trước khi split. Mô hình học tần suất từ của ~~trước~~ từ tập test trước → overfitting

5. - Precision: Trong các mẫu mô hình đoán là positive bao nhiêu % đoán đúng? → báo động giả (FP)

- Recall: Trong các mẫu thực tế Pos, mô hình bắt trúng được bao nhiêu %. → bỏ sót (FN)

6. Thêm bigram cải thiện sentiment classification do giúp thứ tự cục bộ, biến các cụm "not good", "not worth" thành đặc trưng riêng.

HAI TIEN

Được quét bằng CamScanner