Reflection

[17] Numerical stability
Phép trừ $\max(x)$ không làm thay đổi kết quả vì softmax có tính bất biến với phép tịnh tiến

$$\frac{e^{x_i - \max(x)}}{\sum_j e^{x_j - \max(x)}} = \frac{e^{x_i} \cdot e^{-\max(x)}}{e^{-\max(x)} \sum_j e^{x_j}} = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

Nhân tử $e^{-\max(x)}$ xuất hiện ở cả tử và mẫu nên bị triệt tiêu lẫn nhau, giữ nguyên tỉ lệ xác suất nhưng giúp chia số mũ lớn nhất về 0, tránh tràn số.

[15] Temperature.

| Temperature | Max weight | Entrophy | Nhận xét |
|---|---|---|---|
| 0,5 | 0,8282 | 0,6068 | → phân phối nhọn, tập trung token có score cao → chú ý cực đoan, argmax |
| 1,0 | 0,5945 | 1,1211 | → phân phối chuẩn → giữ chính xác tỉ lệ chênh lệch ban đầu |
| 2,0 | 0,4056 | 1,3181 | → phân phối phẳng và dàn đều hơn. Chênh lệch giữa các trọng số giảm, entrophy cao nhất. Attention chia đều hơn cho các token còn lại, |

[18] Model phân phối trọng số mang tính chọn lọc cao, dồn phần lớn trọng số vào các tính từ / trạng từ quyết định sắc thái câu và giảm thiểu ảnh hưởng các từ trung tính khi tổng hợp vector

[19] Attention distribution thay đổi hoàn toàn và rõ rệt.
Query A (sentiment): Trọng số dồn vào các tính từ, trạng từ cảm xúc → more thấp nhất.
Query B (topic): Top 1 lại là movie còn các từ cảm xúc bị hạ xuống

[23] - sẽ chú ý các token
cat → sleeping và that, adopted → yesterday và is
sleeping → cat
- Attention pattern: Thuần thuý là phân phối trọng số xác suất được tính từ tích vô hướng tính học giữa các vectơ.
Long-wise explanation: là cách con người gán ý nghĩa ngữ pháp (như quan hệ CN-VN, bổ ngữ thời gian) lên các con số đó.

[24] LSTM biểu diễn câu bằng hidden state cuối cùng, được tích lũy thông tin qua từng bước thời gian (O(T)), nên dễ bị nghẽn thông tin và suy hao từ 8 xa
Attention biểu diễn câu bằng context vector là tổng có trọng số thuy xuất

Được quét bằng CamScanner

trực tiếp từ mọi token (O(1)) cho phép chọn lọc thông tin quan trọng ở bất kỳ vị trí nào mà không cần nén theo thời gian.

25 self-attention có vấn đề computational cost khi sequence rất dài
- độ phức tạp $O(T^2)$ attention yêu cầu tính toán và lưu trữ điểm tương quan giữa từng cặp token với nhau nên tích thước ma trận $T \times T$
- Khi phép tính T lớn, chiều dài sequence tăng gấp k lần, RAM / VRAM → $k^2$ lần → OOM.

26 ⊛ Dự đoán đúng
"I thought ... excellent" - positive = P = 0,975
→ Câu thực chuyển hướng ngữ nghĩa phức tạp LSTM dự đoán sai → attention dự đoán đúng với độ tự tin cao.
→ Attention không bị ảnh hưởng bởi thứ tự hay chiều dài câu, nó đồng thời "bắt" được 2 từ đối lập "bad" và "excellent". Trọng số lớn dần vào từ mang sắc thái mạnh giúp context vector tổng hợp đầy đủ thông tin tích cực để phân loại chính xác.
⊛ Dự đoán sai
"I like this movie" - positive >< P = 0,233
→ Câu ngắn, nghĩa rõ ràng cả LSTM và attention đều dự đoán sai.
→ Attention tập trung vào từ khoá cảm xúc like
→ Có thể sai do bước classifier phía sau hoặc bộ trọng số embedding do trong tập dữ liệu "like" thường xuyên xuất hiện trong ngữ cảnh tiêu cực "not like".

29 - Attention cho phép các token tương tác trực tiếp với nhau, giúp mô hình khai thác thông tin ở xa mà không phải truyền thông tin tuần tự qua nhiều bước như RNN / LSTM.
- Chi phí tính toán và bộ nhớ tăng theo $O(T^2)$ với T là độ dài chuỗi, attention phải tương tác giữa các cặp token.

**Learning check**

① Attention score được tính bằng $s_i = q^T k_i$ (q: query, k: key) độ tương đồng trong không gian vector giữa thông tin đang tìm kiếm và đặc trưng của token.
② Dùng softmax để chuẩn hoá các điểm score thu ý thành phân phối xác suất hợp lệ. Hàm số e giúp phóng đại sự khác biệt, dồn trọng số cho score cao nhất
③ Q: Đại diện cho thông tin đang cần tìm kiếm
K: Vector đặc trưng dùng để so khớp độ liên quan Q
V: Nội dung thông tin thực tế được trích xuất đưa vào biểu diễn.

Được quét bằng CamScanner

④ Context vector là tổng tổ hợp tuyến tính có trọng số của các vector theo phân phối attention $c = \sum \alpha_i v_i$

⑤ Scaled dot-product attention chia cho $\sqrt{d_k}$ vì khi $d_k$ lớn, phương sai của tích vô hướng tăng mạnh → lệ với $d_k$, dẫn score cao → softmax rơi vào vùng bão hòa. Chia cho $\sqrt{d_k}$ giúp kéo phương sai về 1, ngăn chặn triệt để lỗi vanishing gradient.

⑥ Self-attention khác attention ở:
- Attention thường thường: Q đến từ nguồn khác (decoder), K, V đến từ chuỗi đầu vào (encoder)
- Self-attention cả Q, K, V đều được chiếu tuyến tính sinh ra từ chính cùng một chuỗi đầu vào X, cho phép các từ trong cùng 1 câu tương tác trực tiếp với nhau.

⑦ Độ kích thước ma trận $(T \times T)$, khi sequence dài gấp 2, kích thước và số phần tử của attention matrix sẽ tăng gấp 4.

⑧ Attention không ~~dần~~ chứng minh model đang reasoning. Vì attention weights chỉ là phân phối xác suất thông kê thuần túy bị mất mát theo hàm mất mát, không phải là bằng chứng cho thấy mô hình thực sự hiểu ngữ nghĩa hay tư duy logic như con người.

⑨ Attention xử lý long-range interaction tốt hơn recurrent state vì đường dẫn kết nối giữa 2 từ bất kì qua attention là trực tiếp với độ dài $O(1)$, không bị nén hoặc đi qua T bước thời gian như RNN, bảo toàn thông tin về khoảng cách xa.

Được quét bằng CamScanner