Reflection

11. Do self attention có tính hoán vị đối xứng và không mang thứ tự vị trí, việc đổi thứ tự từ chỉ hoán đổi các hàng trong ma trận đầu ra mà không làm thay đổi giá trị biểu diễn. Khi tổng hợp câu bằng mean pooling → biểu diễn trung bình → mô hình thành bag of words và mất cấu trúc ngữ pháp

12. Khoảng cách tăng từ 0 → 4,0479 khi bổ sung PE → PE giúp Transformer nhận biết thứ tự từ.

15. Sử dụng $x + F(x)$ tạo ra một đường truyền tắt giúp bảo toàn trực tiếp thông tin đầu vào x qua các tầng, thay vì để thông tin bị suy hao hay biến dạng nếu chỉ dùng $F(x)$ → giúp gradient luôn có 1 thành phần = 1 truyền thẳng về các tầng trước, loại bỏ hiện tượng mất đạo hàm.

19. - Tăng số heads không làm tăng representation dim do tổng chiều biểu diễn luôn cố định ở dmodel = 128 (tham số = 1.545.546)
- Khi dmodel cố định, tăng số heads làm dk giảm ($d_k = \frac{d_{model}}{n_{heads}}$)

20. Có. Multi-head attention tạo ra các attention patterns đa dạng tập trung mạnh (head 3, 2); phân tán (head 1, 4)

21. Có thể xuất phát từ cơ chế self attention (+ cặp từ tương tác trực tiếp với nhau; multi head attention (quan sát ~~thay vì~~ nhiều không gian biểu diễn); residual connection + layer norm (luồng gradient truyền trực tiếp và ổn định)

22. tăng độ dài chuỗi từ 32 → 256 → cách thức ma trận tăng 64 lần → bộ nhớ tăng 67 lần → thời gian huấn luyện tăng 5 lần
⇒ Tăng tỷ lệ sequence length → OOM.

25. Có. Do mean pooling tổng hợp trực tiếp thông tin từ + token trong câu, CLS-style buộc mô hình dồn nén ngữ cảnh vào vị trí đầu tiên.

Được quét bằng CamScanner

28

Prediction	Dự đoán ban đầu	Thực tế	Đ/S	Giải thích
1	Có	Có	Đ	Không có vòng lặp phụ thuộc thời gian, toàn bộ sequence xử lý đồng thời qua QKT.
2	Không	Không	Đ	Self attention k phụ thuộc vị trí, PE mới khái niệm từ nào trước, từ nào sau
3	Không	Không	Đ	Khi không có PE và dùng mean pooling, vector đại diện 2 câu khác nhau
4	Không	Không	Đ	8 head tập trung vào từ lân cận, 8 head phân tán đều → đa dạng
5	Có	Không chắc chắn	S	Khi d_model cố định, 1 head làm giảm chiều dài riêng của mỗi head. dk nhỏ → khả năng biểu diễn của head yếu đi → overfitting hoặc head thừa
6	Có	Không	S	Transformer có độ phức tạp tính toán và bộ nhớ mà train là $O(T^2)$, RNN là $O(T)$. sequence length dài → chi phí ma trận TxT lớn → OOM.

27 TF-IDF
↓ Biểu diễn thưa, chiều vector lớn, không bắt được ngữ nghĩa tương đồng và bỏ qua hoàn toàn thứ tự từ.

Word2Vec
↓ Biểu diễn tĩnh - mỗi từ chỉ có 1 vector cố định, không phân biệt được đa nghĩa theo ngữ cảnh, khi lấy trung bình vẫn mất thứ tự từ

LSTM
↓ Bắt buộc tính tuần tự (k thể song song) → bottleneck → phải nén chuỗi vào hidden state.

Attention (RNN + Attention)
↓ Kiến trúc tuần tự của RNN → chậm, không song song hoá hoàn toàn

Transformer
↓ Độ phức tạp tính toán và bộ nhớ tăng theo độ dài chuỗi, thiếu inductive bias nên cần dữ liệu không lớn để học tốt.

Được quét bằng CamScanner

Learning check

① self attention có tính chất hoán vị đối xứng, ko có trục thời gian, thiếu PE, mô hình coi là bag of words

② single head → 1 không gian
Multi — nhiều ___ con (dk) → học được ngữ nghĩa / ngữ pháp

③ $d_k = \frac{d\ model}{n\ heads} = \frac{128}{8} = 16$

④ Vì ma trận tính toán điểm tương tác giữa các token có vai trò Query - key

⑤ Residual connection giúp bảo toàn thông tin gốc ban đầu → gradient truyền thẳng → chặn vanishing gradient

⑥ FFN thực hiện biến đổi phi tuyến tính độc lập từng vị trí → giàu năng lực biểu diễn đặc trưng qua bước attention

⑦ Vì transformer không có tầng thái còn phụ thuộc tuần tự, ∀ phép tính trên toàn bộ chuỗi thực hiện thông qua ma trận GPU

⑧ Nếu sequence dài gấp đôi, attention matrix tăng gấp 4 lần do độ phức tạp tăng theo bậc 2

⑨ Vì attention weights chỉ là phân phối trung gian trong phép tuyến tính sau đó vector còn trải qua các phép biến phi tuyến phức tạp.

Được quét bằng CamScanner